



Trabajo Práctico 1

Ciencia de datos

Alumnos

Francesca Castronuovo, Justo Guastavino, Isabella Canale.

Profesores

María Noelia Romero, Ignacio Anchorena, Tomás Enrique Buscaglia

Grupo 18

Marco Teórico

La Encuesta Permanente de Hogares (EPH) es un programa nacional de producción sistemática y permanente de indicadores sociales que lleva a cabo el Instituto Nacional de Estadística y Censos (INDEC), que permite conocer las características sociodemográficas y socioeconómicas de la población (INDEC, 2003). Dentro de esta evaluación social, podríamos investigar los diferentes parámetros que constituyen el mercado laboral; en este trabajo nos centraremos específicamente en el indicador de pobreza. El INDEC, define que ‘a partir de los ingresos de los hogares se establece si [los individuos] tienen capacidad de satisfacer -por medio de la compra de bienes y servicios- un conjunto de necesidades alimentarias y no alimentarias consideradas esenciales. El procedimiento parte de utilizar una canasta básica de alimentos (CBA) y ampliarla con la inclusión de bienes y servicios no alimentarios (vestimenta, transporte, educación, salud, etc.) con el fin de obtener el valor de la canasta básica total (CBT). Para calcular la incidencia de la pobreza se analiza la proporción de hogares cuyo ingreso no supera el valor de la CBT’ (2005?).

PARTE I: Limpieza de Datos

Como primer paso para poder familiarizarnos con la EPH y comenzar a analizar el indicador de pobreza, decidimos comparar los datos obtenidos en el primer trimestre de dos años distintos: 2005 y 2025, con el fin de poder investigar las fluctuaciones en los patrones de los indicadores sociales dentro de un lapso de dos décadas. Para ello, comenzamos descargando de la web del INDEC los microdatos de la EPH para el primer trimestre de 2005 y del 2025 , junto con el documento “Diseño de registro y estructura para las bases preliminares (hogares y personas)” para cada año. Ese diccionario se utilizó para identificar significados, rangos válidos y codificaciones de no respuesta de todas las variables empleadas. Luego, definimos como ámbito de análisis la región patagónica, filtramos ambas bases para conservar únicamente las observaciones pertenecientes a dicha región y unimos los dos trimestres en una sola base para preservar la comparabilidad.

Como siguiente paso, elegimos 15 variables de interés¹, e hicimos una revisión de las mismas para identificar valores extraños o inconsistentes , tales como: celdas sin respuestas, ingresos negativos, edades imposibles y respuestas categorizadas como 99/98 o ‘no sabe/no contesta’ . Dichos datos, los reemplazamos por el código NaN, con el fin de homogeneizar la

¹ Sexo, Edad, Estado civil, Cobertura médica, Nivel educativo, Condición de actividad, Categoría de inactividad, Ingreso per capita familiar (IPCF), Lugar de nacimiento, Alfabetización, Si busco trabajo, Cantidad de horas de trabajo en la ocupación principal, Hace cuanto tiempo trabaja, Hace cuanto tiempo esta desocupado y Categoría de ocupación.

representación de este tipo de respuestas y para no sesgar los análisis posteriores por datos inválidos.

Para nuestra sorpresa, muchas variables de la base de 2005 estaban codificadas en letras y no en códigos. Para simplificar análisis posteriores y para poder unificar las dos bases y que estén ambas codificadas de la misma manera, creamos diccionarios que asignan un código numérico a las categorías que en 2005 estaban registradas como texto (por ejemplo, “Varón” → 1, “Mujer” → 2). Esto nos permitió unificar los formatos y así poder comparar y combinar ambas bases. También definimos que las respuestas inválidas o no declaradas se registren como valores faltantes (NaN). Aplicamos esos diccionarios a las variables de la base 2005. Para cada columna, el código buscó el valor en el diccionario correspondiente y lo reemplazó por su número. Si el valor no estaba en el diccionario, se lo reemplazó por NaN. De esta forma, logramos que las variables de 2005 tengan la misma codificación que en 2025.

Posteriormente, con este análisis y reconfiguración de valores, realizamos *heatmap* (ver **Fig.1**) con la finalidad de observar la distribución de los valores faltantes (NaN) sobre las 15 variables para cada uno de los años de análisis. El diagnóstico resultante a partir del mapa de calor fue el siguiente: Las variables sociodemográficas presentan cobertura casi completa en 2005 y 2025. En cambio, es observable que los faltantes se concentran en el módulo laboral. Tanto para el año 2025 como para el 2005, se halló que la mayor cantidad de NaN se aglomeran en las variable PP104 (tiempo destinado a la búsqueda de trabajo), PP10E (tiempo de desocupación de un individuo) y PP70A (tiempo trabajando); y en menor medida en CAT_OCUP y CAT_INAC) Estos resultados coinciden con el hecho de que dichas preguntas no son realizadas ni corresponden a todos los encuestados.

PARTE II: Análisis exploratorio

En primer lugar, construimos un gráfico de barras con la composición por sexo en los años 2005 y 2025 para la región seleccionada (ver **Fig. 2**). Los resultados muestran que la distribución entre varones (en 2005, n=1575 y en 2025, n=2650) y mujeres (en 2005, n=1654 y en 2025, n=2709) se mantiene bastante equilibrada en ambos períodos, con una ligera mayoría femenina. Si bien el tamaño de la muestra es mayor en 2025, la proporción relativa entre sexos prácticamente no se modifica, lo que indica estabilidad en la composición poblacional a lo largo del tiempo.

Posteriormente realizamos una matriz de correlación (ver **Fig. 3** y **Fig 4**) con las variables CH04, CH06, CH07, CH08, NIVEL_ED, ESTADO, CAT_INAC, IPCF. Para

realizar el gráfico, fue necesario crear variables dicotómicas binarias (variables dummies) para poder renombrar variables categóricas (como CHO4) con etiquetas legibles y adecuadas. Luego dividimos los datos por año y calculamos la matriz de correlación para cada una de las 8 variables respectivamente. Los resultados obtenidos demuestran patrones esperados para tanto 2005 como para 2025: el ingreso per cápita familiar (IPCF) se asocia positivamente con el nivel educativo y con la condición de ocupado, mientras que muestra correlaciones negativas con la variable de desocupación/inactividad. La edad, correlaciona positivamente con subcategorías de inactividad ligadas al retiro y negativamente con la condición de estudiante. Asimismo, es importante notar que entre las dummies de un mismo ‘grupo’ (ocupado, desocupado, inactivo) aparecen correlaciones altas porque se excluyen entre sí: si una vale 1, las otras valen 0, por lo que no debe leerse ni entenderse como efecto causal sino un efecto de diseño. En general, las magnitudes de correlación son bajas a moderadas y las diferencias entre 2005 y 2025 son pequeñas, manteniendo un patrón general.

PARTE III: Conociendo a los pobres y no pobres

En esta última parte del trabajo nos centramos en el análisis de pobreza. Para poder avanzar en esta dirección es necesario revisar primero la calidad de los datos de la EPH, ya que uno de los principales problemas de la encuesta es la falta de respuesta en variables sensibles como la condición de actividad y los ingresos. La correcta identificación de estos casos resulta fundamental, dado que los hogares sin información confiable no pueden ser evaluados en términos de suficiencia económica.

En primer lugar, analizamos la variable condición de actividad (ESTADO). En total, identificamos 13 observaciones sin respuesta, lo que representa apenas el 0,2% de la muestra conjunta de 2005 y 2025. Al desagregar por año, se observa que en 2005 hubo 2 casos y en 2025 fueron 11. Dado que se trata de una proporción muy baja, concluimos que la falta de respuesta en esta variable no introduce un sesgo relevante en el análisis posterior. En cuanto al ingreso total familiar (ITF) se observa que en 2005 la no respuesta fue mínima: solo 23 hogares no declararon ingresos, lo que representa una tasa de no respuesta de 0,7%. En cambio, en 2025 la magnitud del problema se incrementa significativamente: 1.202 hogares no informaron sus ingresos, lo que equivale a una tasa de no respuesta cercana al 22,4%.

A partir de esta información, se generaron dos bases de datos nuevas; una incluye aquellos sujetos que respondieron a ITF y otra que incluye a los que no respondieron. A partir de esto, trabajamos con la base *respondieron* (total de 7.363 datos) en los cálculos posteriores de pobreza, ya que sin información de ingresos no es posible establecer el análisis correspondiente.

Para poder calcular la pobreza fue necesario incorporar las necesidades energéticas. Para ello utilizamos la tabla provista, que asigna un valor distinto según el sexo y la edad de cada persona. Primero generamos una variable que agrupa la edad en los rangos definidos por la tabla y otra que diferenciaba entre varones y mujeres. Luego unimos la base principal con la tabla de adultos equivalentes, de manera que cada individuo recibiera el valor correspondiente según su sexo y edad. Finalmente, agrupamos por hogar utilizando la variable de la base original *CODUSU*² y *NRO_HOGAR*³ (todos los miembros del hogar tienen el mismo valor en estas variables (INDEC, 2025)), de manera que todos los miembros del mismo hogar se sumarán y sumamos estos valores, construyendo la variable *ad_equiv_hogar*, que representa la cantidad total de adultos equivalentes en cada hogar. Esta variable será clave en los cálculos posteriores de necesidades mínimas de ingreso.

Luego, se ha agregado una columna llamada “*pobre*” donde el *ITF* toma el valor de 1 si el ingreso de la familia es menor que el necesario y 0 en el caso contrario. En el año 2005 se han registrado 570 familias consideradas pobres en 3206 filas en total, lo que nos deja con un 17.8% de pobreza en la muestra total. En cambio, en el año 2025 se han registrado 570 familias dentro del criterio de pobreza, en total son 4157 individuos involucrados, porcentualmente de la muestra son un total de 20.8% de pobres. En el gráfico de barras que se comparan los porcentajes de pobreza (figura 6) se puede observar la diferencia leve entre los porcentajes de pobreza precisamente un 3%.

La estadística descriptiva de la muestra de pobreza en 2005 muestra que la media fue equivalente a 17.779164 y un desvío estándar de 0.382397 (n=3206). Por otro lado en la muestra de 2025 (n=4157) la media fue de 20.808275 y el desvío estándar fue de 0.405985, en ambos caso la mediana fue de 0.0.

² Código para distinguir viviendas, permite aparearlas con Hogares y Personas. Además permite hacer el seguimiento a través de los trimestres

³ Código para distinguir Hogares, permite aparearlos con Personas

Por último, en el gráfico compara el ingreso per cápita de personas pobres y no pobres en los años 2005 y 2025(figura 7), usando escala logarítmica. En 2005 se observa una marcada brecha, los no pobres tenían ingresos muy superiores y más dispersos, mientras que los pobres se concentran en niveles bajos, con algunos casos extremos muy reducidos. Para 2025, ambos grupos muestran un fuerte incremento en sus ingresos, pero la desigualdad relativa persiste, aunque los pobres mejoran respecto a 2005, siguen ubicados por debajo de los no pobres, que alcanzan niveles aún más altos. En conclusión, los ingresos crecieron en general, esto pudo haber sido causado por la inflación, pero la brecha entre pobres y no pobres sigue siendo evidente.

Figura 1: Heatmap




Figura 2: Gráfico de barras




Figura 4: Matriz de correlación 2005




Figura 5: Matriz de correlación 2025




Figura 6: Grafico de barras comparando porcentaje de pobreza de 2025 y 2005




Figura 7: Box plot de Ingreso per cápita por condición de pobreza y año

